Orquestación condicionada con decisión calibrada: cuándo actuar, preguntar, escalar, abstenerse o recordar

Gustavo Mora · Investigador independiente, Buenos Aires, Argentina
ORCID: 0009-0004-5276-3066
Propuesta de investigación · Preprint no revisado por pares · **Versión 4.2**. Diseño preespecificado; DG-E1 todavía no se ejecutó.

Resumen

Un sistema basado en modelos de lenguaje (LLM), agentes y skills debe decidir, antes de ejecutar, qué hacer con una petición: actuar con la mejor interpretación disponible, preguntar, escalar a otro ejecutor, abstenerse o, como paso previo combinable, recordarle al usuario un recurso que ya posee. Elegir entre actuar y preguntar mediante umbrales de utilidad esperada tiene una tradición larga, desde la iniciativa mixta y la regla de rechazo de Chow hasta los marcos recientes de valor de la información para agentes LLM. Esta propuesta parte de esa base y aporta tres elementos de integración y de diseño de evaluación, no una novedad matemática. Primero, recordar se trata como componente explícito de la misma regla de decisión, con sus interacciones de utilidad declaradas. Segundo, la evaluación separa discriminación de calibración: con presupuesto ordinal de interrupciones igualado y la misma resolución de empates, una recalibración estrictamente creciente no cambia ninguna decisión; por eso, en esa comparación de un score, la calibración solo puede importar cuando los umbrales se derivan de costos fijados de antemano, y su valor se mide como regret. Tercero, una arquitectura de separación de roles y una auditoría de acumulación en el umbral protegen la probabilidad que entra a la decisión, motivadas por resultados teóricos recientes según los cuales un componente premiado a la vez por calibración y por autonomía infla la confianza que reporta. Se propone un experimento offline (DG-E1) con casos etiquetados que cubre actuar, preguntar, abstenerse y recordar, con un brazo que contrasta la amenaza de inflación. Su métrica primaria (reducción de regret por recalibración, DG-H1b), sus márgenes y su tamaño de muestra se fijarán en un preregistro antes de abrir la partición de prueba; ese experimento todavía no se ejecutó y el diseño general no está íntegramente congelado. Todo resultado numérico del texto es derivado o simulado, salvo un piloto ilustrativo de ocho decisiones. Un resultado negativo es un resultado válido. Una implementación operativa de alcance reducido (PO430, 430 pedidos; hipótesis principal PO430-H1 sobre inflación) se relaciona con este diseño en la sección 5.11 y no sustituye la hipótesis primaria aquí definida.

Palabras clave: decisión bajo incertidumbre, calibración, valor de la información, opción de rechazo, iniciativa mixta, colaboración humano–agente, incentivos, preregistro.

1. Introducción

Los agentes que ejecutan skills reciben peticiones en lenguaje natural que casi siempre dejan algo sin especificar. Antes de producir un resultado, el sistema tiene que resolver, de forma explícita o implícita, qué hacer con la petición. Esta propuesta trata esa elección como una decisión bajo incertidumbre y pregunta cuándo cada opción compensa su costo, con qué certeza puede afirmarse que lo compensa y quién fija el riesgo aceptable. La decisión se apoya en una probabilidad de haber interpretado correctamente la petición; bajo el supuesto de que una interpretación correcta se ejecuta bien (idealización global declarada en la sección 3.2), esa probabilidad determina el éxito esperado del entregable. Con beneficios, costos de error y costos de interrupción declarados, esa probabilidad se convierte en utilidad esperada, y los umbrales resultantes fijan cuánta autonomía se concede según el riesgo de cada clase.

1.1 Salidas

Cuatro salidas son mutuamente excluyentes dentro de un turno, más un paso previo combinable:

- **Actuar:** ejecutar con la mejor interpretación, declarando los supuestos.
- **Preguntar:** pedir una aclaración y después ejecutar.
- **Escalar:** delegar la ejecución o la decisión a otro ejecutor. Hay dos subtipos con costos y tasas de éxito distintos: una solución multiagente (costo de cómputo) y una persona (costo de atención).
- **Abstenerse:** no ejecutar, informar el motivo y dejar la tarea abierta.
- **Recordar (paso previo, no salida):** mostrarle al usuario un recurso propio que podría resolver o abreviar la tarea. Puede acompañar a cualquiera de las cuatro salidas.

Cada opción tiene un beneficio posible y un costo posible. Las instrucciones ambiguas conducen con frecuencia a invocaciones incorrectas de herramientas, y no pedir aclaración es un modo de fallo documentado de los sistemas multiagente (Suri et al., 2026; Cemri et al., 2025). Preguntar consume atención, así que su beneficio esperado debe compararse con su costo cognitivo (Dong et al., 2026), y ese costo varía según la persona y el contexto (Horvitz y Apacible, 2003). Escalar a una solución multiagente consume cómputo y latencia, y las arquitecturas de agentes más complejas a menudo no superan a baselines simples cuando se controla el costo (Kapoor et al., 2024). Recordar el recurso equivocado interrumpe sin beneficio; los asistentes proactivos que sugieren demasiado pierden la preferencia de los usuarios y perturban el flujo (Chen et al., 2025; Pu et al., 2025).

1.2 Quién produce la probabilidad

Hay un segundo problema que suele quedar implícito. Si el mismo componente que reporta la probabilidad se beneficia de actuar sin preguntar, tiene un incentivo para inflarla, y la regla de umbral pierde sentido aunque el registro muestre un Brier aceptable (Lovén et al., 2026). Esta propuesta trata el origen de la probabilidad como una decisión de diseño, no como un dato.

1.3 Contribuciones

La regla de umbral es clásica (Pauker y Kassirer, 1980; Chow, 1970), y trabajos recientes ya la aplican a agentes LLM mediante el valor de la información (Dong et al., 2026; Suri et al., 2026). No se reclama novedad matemática. Las contribuciones son de integración y de diseño de evaluación:

1. **Recordar como componente explícito** de la misma regla, con sus interacciones con la salida declaradas y un subconjunto etiquetado propio de casos donde el usuario ya posee el artefacto.
2. **Una evaluación que separa discriminación de calibración.** Con presupuesto igualado solo importa el orden de los scores. Este trabajo propone evaluar la calibración solo con umbrales derivados de costos y reportarla como regret frente al umbral óptimo ex post; la invariancia que lo motiva es conocida (sección 2).
3. **Separación de roles y auditoría de acumulación en el umbral** aplicadas a un sistema con costos de atención, junto con un brazo experimental que induce un incentivo de autonomía y mide si las probabilidades reportadas se apilan justo arriba del umbral.

Como línea futura, no desarrollada aquí, se propone contrastar la heterogeneidad entre usuarios antes de personalizar la autonomía.

Una búsqueda no sistemática en octubre de 2026 no encontró un trabajo que reúna estos tres elementos con esa línea futura. Eso no demuestra una brecha. La novedad que se reclama es la combinación y el diseño de evaluación, no la regla ni los resultados matemáticos.

1.4 Alcance

El Experimento 1 (DG-E1) cubre actuar, preguntar, abstenerse y recordar, offline, sobre casos etiquetados, y compara una heurística, un modelo logístico interpretable y su versión recalibrada. Escalar se formaliza pero se difiere, igual que la autonomía personalizada, la memoria de largo plazo, los modelos latentes y de estados de sesión, la inferencia causal y el aprendizaje continuo.

2. Antecedentes

La decisión de actuar, preguntar o abstenerse se apoya en varias líneas de trabajo; lo que esta propuesta agrega es su combinación con recordar y con probabilidades robustas a incentivos. La búsqueda fue web y no sistemática (octubre de 2026); los preprints de 2026 no pasaron revisión por pares.

Línea de trabajo	Referencias clave	Qué toma esta propuesta
Iniciativa mixta y umbrales de decisión	Horvitz (1999); Pauker y Kassirer (1980)	La regla de utilidad esperada entre actuar, dialogar y no actuar; umbrales derivados de costos
Opción de rechazo y clasificación selectiva	Chow (1970); El-Yaniv y Wiener (2010); Geifman y El-Yaniv (2017)	La abstención como opción de rechazo con costos explícitos; análisis riesgo–cobertura
Aprender a diferir	Madras, Pitassi y Zemel (2018); Mozannar y Sontag (2020)	Escalar a una persona como diferimiento; la tasa del experto como p_E
Cuándo preguntar en agentes LLM	Kobalczyk et al. (2025); Suri et al. (2026); Dong et al. (2026); Ren et al. (2023)	Cuándo preguntar y valor de la información frente al costo cognitivo; pedir ayuda con conjuntos conformales como comparador
Costo de interrupción y autonomía ajustable	Horvitz y Apacible (2003); Horvitz, Koch y Apacible (2004); Yuan et al. (2017); Scerri et al. (2002); Parasuraman et al. (2000); Feng et al. (2025)	El costo de atención es medible y heterogéneo; niveles de autonomía como decisión de diseño
Incentivos y calibración	Lovén et al. (2026); Holmström (1984); Perdomo et al. (2020)	Inflación bajo premio a la autonomía; separación de roles; predicción performativa
Calibración más allá del promedio	Hébert-Johnson et al. (2018); Dwork et al. (2021)	Calibración por clase de riesgo como forma mínima de multicalibración (Hébert-Johnson et al., 2018); Dwork et al. (2021) como antecedente de indistinguibilidad de resultados
Recuperación de skills y recuerdo proactivo	Li et al. (2025); Zheng et al. (2026); Yang et al. (2026); Yao et al. (2026); Rhodes y Maes (2000); Ye y Fischer (2002); Lu et al. (2024)	La recuperación es estándar; decidir si mostrarle al usuario lo que ya posee es la parte abierta
Enrutamiento y parada temprana	Ding et al. (2025); Yue et al. (2025); Raj et al. (2026); Ruan et al. (2026)	Escalar se difiere; un baseline simple será obligatorio

Posicionamiento. Ya existen: la regla de utilidad esperada para actuar, preguntar o no hacer

nada; la opción de rechazo con costos y su versión selectiva; el diferimiento a un experto; el valor de la información para agentes LLM; pedir ayuda con garantías conformales; y el conflicto entre calibración y beneficio de actuar. También se sabe que las magnitudes basadas en el orden, como las curvas riesgo–cobertura y el AUROC, son invariantes ante transformaciones monótonas del score. La sección 4.3 no presenta esto como hallazgo; extrae su consecuencia para cómo debe evaluarse la calibración en los estudios sobre aclaraciones.

3. Marco de decisión

Todos los umbrales por pares de esta propuesta salen de una sola regla: elegir la salida habilitada de mayor utilidad esperada. El marco es de decisión de un paso: cada petición se decide una vez, con la información disponible, y alcanza con una pregunta. Las extensiones secuenciales (cadenas de Markov, MDP o POMDP sobre estados de sesión) son de interés intelectual y posibles extensiones futuras, pero no forman parte del modelo evaluado. Rótulos usados en el texto: [DEF] definición, [DEM] derivado aquí bajo los supuestos declarados, [SUP] supuesto (con lo que se rompe si falla), [HEUR] juicio de diseño, [CONJ] conjetura contrastable.

3.1 Notación

Símbolo	Significado
x	Información disponible al momento de decidir
Y	Resultado primario: 1 si el entregable final cumple el criterio de éxito preregistrado del caso
Y_1, Y_2, Y_r	Interpretación correcta en atributos críticos; relevancia material del recurso candidato; una aclaración resuelve la ambigüedad
$p,\ r$	$P(Y_1 = 1 \mid x)$; $P(Y_r = 1 \mid x)$
$\tilde{p},\ \hat{p}$	Probabilidad declarada (cruda) por un LLM o una persona; estimación calibrada
$b,\ c,\ k$	Beneficio de una ejecución correcta; costo de un error; costo de interrumpir para preguntar
$p_E,\ k_E$	Probabilidad de éxito y costo del ejecutor alternativo
$q_2,\ \alpha,\ W,\ k_R$	$P(Y_2 = 1 \mid x)$; $P(\text{adopta} \mid \text{relevante})$; trabajo evitado; costo de la interrupción de recordar
$S(\pi),\ N_{int}(\pi),\ T(\pi)$	Tasa de éxito, interrupciones por tarea y tokens por tarea de la política π
R0–R3	Clases de riesgo con irreversibilidad e impacto crecientes

[SUP] p es condicional a la información disponible al decidir. Si x incluye información posterior a la decisión, la evaluación tiene fuga.

Lectura de p, Y y Y_1 [DEF]. $p = P(Y_1 = 1 \mid x)$ es la probabilidad de haber acertado la **interpretación** en los atributos críticos definidos de antemano; no afirma por sí sola que la ejecución sea correcta, ni que la política discrimine, ni que el sistema sea seguro. Y es el resultado del entregable final (criterio de éxito preregistrado del caso). Y_1 es un predictor intermedio. Un protocolo operativo puede etiquetar «entendió» sobre la interpretación (cercano a Y_1); esa etiqueta no sustituye a Y del marco ni a la calidad de ejecución.

3.2 Actuar frente a no hacer nada, y frente a preguntar

Las magnitudes b, c y k se miden en las mismas unidades (unidades de b cuando se fija $b = 1$); $r \in [0, 1]$ es una probabilidad. Una acción que es correcta con probabilidad p (beneficio b) y

errónea en el resto de los casos (costo c), frente a una alternativa nula, conviene si y solo si [DEM]:

$$p\,b - (1-p)\,c > 0 \iff p > p_0 = \frac{c}{b+c}$$

Es el umbral clínico de Pauker y Kassirer (1980) y, con la abstención como alternativa nula, la regla de rechazo de Chow (1970).

[SUP] Idealización de interpretación y ejecución. En las derivaciones de decisión, el éxito al actuar con la interpretación inicial se identifica con el acierto de esa interpretación:

$$P(Y^{\text{act}} = 1 \mid Y_1 = 1, x) = 1, \qquad P(Y^{\text{act}} = 1 \mid Y_1 = 0, x) = 0.$$

Esto equivale a $Y^{\text{act}} = Y_1$ casi seguramente en el modelo idealizado ($e_1 = 1$, $e_0 = 0$); no es una afirmación de ejecución perfecta observada. La pregunta conserva una interpretación inicialmente correcta, corrige una incorrecta con probabilidad r y no cambia el mecanismo de ejecución condicionado a la interpretación final; si no aclara, el modelo aquí derivado actúa de todos modos. Usar $r = P(Y_r = 1 \mid x)$ supone independencia de la resolución respecto del acierto inicial dado x; sin ello haría falta $r_0 = P(\text{corrige} \mid Y_1 = 0, x)$. El resultado Y del entregable final se mide por separado. Las reglas son óptimas bajo esta idealización y las acciones habilitadas; fuera de ella no se garantiza que calibrar $p = P(Y_1 = 1 \mid x)$ calibre el éxito final. La comparación con escalar debe usar el mismo resultado de éxito y las mismas unidades de utilidad. Las ecuaciones de esta sección se recuperan exactamente con $e_1 = 1$, $e_0 = 0$ y $r_0 = r$.

Sea k el costo de interrumpir y r la probabilidad de que la aclaración resuelva la ambigüedad. Bajo la idealización anterior [SUP]:

$$E[U(\text{preguntar})] = [p + (1-p)\,r]\,b - (1-p)(1-r)\,c - k$$

$$E[U(\text{actuar})] - E[U(\text{preguntar})] = k - (1-p)\,r\,(b+c)$$

Actuar es preferible a preguntar si y solo si [DEM]:

$$p > p^* = 1 - \frac{k}{r\,(b+c)}$$

El umbral depende de k y de r, no solo de $c/(b+c)$.

3.3 Valor de la aclaración (incrementos frente a actuar)

Bajo la idealización de la sección 3.2, una revelación de la intención que permite corregir la interpretación y ejecutar correctamente tiene utilidad b. Su incremento bruto frente a *actuar con la interpretación inicial* es [DEM]

$$V^{\text{act}}_{\text{perfecta}} = b - E[U(\text{actuar})] = (1-p)(b+c).$$

Una pregunta del modelo especificado tiene incremento bruto y neto frente a esa misma alternativa

$$V^{\text{act}}_{\text{preg,bruto}} = r(1-p)(b+c), \qquad V^{\text{act}}_{\text{preg,neto}} = r(1-p)(b+c) - k.$$

Estos incrementos reproducen el cruce actuar/preguntar (p^*); no son automáticamente el EVPI o el EVSI de la política completa. Conocer si $Y_1 = 1$ no equivale a conocer la interpretación correcta cuando $Y_1 = 0$.

Para un experimento informativo Z y un conjunto de acciones A fijado,

$$\text{EVSI}(Z) = E_Z\big[\max_{a \in A} E(U(a) \mid x, Z)\big] - \max_{a \in A} E(U(a) \mid x),$$

y el EVPI usa revelación perfecta del estado pertinente; los costos de adquisición se restan después. Si las opciones fueran solo actuar o abstenerse, EVPI $= b - \max(0,\, E[U(\text{actuar})])$, que coincide con $(1-p)(b+c)$ solo si $E[U(\text{actuar})] \geq 0$. Ese ejemplo aclara el baseline y no introduce una opción posterior: el modelo obliga a actuar después de preguntar, y un incremento neto positivo frente a actuar no basta para elegir preguntar en el argmax global. Si preguntar mejora la calidad más allá de la interpretación, la idealización de la sección 3.2 está fallando.

3.4 Regla general

Con un conjunto A de salidas habilitadas, la política elige [DEF]:

$$a^* = \arg\max_{a \in A} E[U(a)], \qquad U(\text{esc}) = p_E\, b - (1 - p_E)\, c - k_E, \qquad U(\text{abs}) = 0$$

Se supone $b > 0$, $c, k \geq 0$ y $r, p \in [0, 1]$, con utilidades y costos en la misma unidad. El umbral p^* se escribe solo si $r > 0$. No se presupone un orden universal de los cruces: decide el argmax, incluidos vetos y desempates. El cruce preguntar/abstenerse, si $r < 1$, es $p_a = 1 - (b-k)/((b+c)(1-r))$; no se introduce como regla nueva. $U(\text{abs}) = 0$ es una normalización: b y c se miden respecto de dejar la tarea sin hacer, de modo que el costo de una tarea abierta queda absorbido en b. Los empates se resuelven en el orden fijo abstenerse, preguntar, escalar, actuar (primero el más conservador) [HEUR].

La taxonomía sigue cuatro distinciones [HEUR]. Abstenerse no es escalar, porque nadie ejecuta ($U = 0$): es la distinción entre rechazo (Chow) y diferimiento (Madras et al.). Escalar tiene dos subtipos con (p_E, k_E) distintos. Preguntar no es escalar a una persona, porque preguntar pide información y el sistema sigue ejecutando, mientras que escalar transfiere la decisión. Recordar no es una salida, porque nunca resuelve la tarea por sí solo.

Casos extremos bajo la idealización: si $r = 0$, preguntar rinde lo mismo que actuar menos k; con $k = 0$ hay empate y rige el desempate declarado, no el cociente 0/0. Si $0 < k < r(b+c)$, $p^* \in (0, 1)$; si $k \geq r(b+c)$, preguntar no mejora estrictamente actuar (la igualdad se desempata; abstenerse todavía puede ganar). Si $k = 0$ y $r > 0$, preguntar mejora actuar para $p < 1$ y empata en $p = 1$. Si $r = 1$, preguntar rinde $b - k$. Para $p < 1$ y $r < 1$ fijos, si $c \to \infty$, actuar y preguntar tienden a $-\infty$; no ocurre así si $p = 1$, ni para preguntar si $r = 1$. Un escalador con $p_E < 1$ fijo tampoco queda exento de ese límite.

3.5 Recordar, con interacciones

El trabajo evitado W solo se materializa si el recurso es relevante y se adopta. En el caso aditivo, recordar compensa si y solo si [DEM]:

$$q_2\, \alpha\, W > k_R$$

La aditividad es un supuesto [SUP] que falla por tres motivos, así que recordar se decide conjuntamente con la salida:

Celda	Utilidad esperada	Término de interacción
Actuar + recordar	$U(\text{act}) + q_2\alpha W - k_R - \omega$	$\omega \geq 0$: solapamiento entre W y b (el trabajo adoptado no se rehace)
Preguntar + recordar	$U(\text{preg}; r') + q_2\alpha W - k_R + \kappa - \omega$	$\kappa \in [0, \text{mín}(k, k_R)]$: una sola interrupción; r': el recurso cambia la respuesta
Escalar o abstenerse + recordar	análogo	el recurso puede volver innecesario escalar

Sea $m \in \{0, 1\}$ el indicador de recordar. La elección conjunta es $(a^*, m^*) \in \arg\max\{U(a) + m\Delta_R(a)\}$ sobre los pares habilitados, con $\Delta_R(\text{act}) = q_2\alpha W - k_R - \omega$ y $\Delta_R(\text{preg}) = q_2\alpha W - k_R + \kappa - \omega + (1-p)(r'-r)(b+c)$. W está en unidades de utilidad y ω es solapamiento esperado. Con $\omega = \kappa = 0$ y $r' = r$ se recupera $q_2\alpha W > k_R$. Se reporta la sensibilidad a $(\omega, \kappa, r' - r, \alpha)$ en rangos preregistrados. Offline, α no se observa: las conclusiones de recordar son condicionales a su rango.

3.6 Clases de riesgo y vetos

Cada clase de riesgo R0–R3 tiene su propio rango preregistrado de (b, c, k) y, por lo tanto, sus propios p_0 y p^*. Cuatro vetos se aplican antes de la regla de utilidad y exigen confirmación sea cual sea el umbral: acciones irreversibles o con efectos fuera de un entorno aislado; acciones fuera de los permisos otorgados; decisiones cuya probabilidad no tiene estado calibrado y validado para esa clase; y costo estimado por encima del presupuesto. Los vetos son reglas, no probabilidades, y no dependen del número que reporta el agente.

El veto de validación exige equivalencia, no ausencia de diferencia. Para la calibración logística $\text{logit}\, P(Y_1 = 1 \mid \hat{p}) = a + s\,\text{logit}\,\hat{p}$, el ideal es $(a, s) = (0, 1)$. Una clase queda habilitada solo si ambos IC al 90 % válidos quedan enteramente dentro de $(-\varepsilon_0, \varepsilon_0)$ para el intercepto (en log-odds) y $(1 - \varepsilon_s, 1 + \varepsilon_s)$ para la pendiente (adimensional); cada condición es un TOST unilateral de nivel 0,05 (Schuirmann, 1987). Exigir ambas es una intersección–unión, no equivalencia por no significación. Valores por defecto: $\varepsilon_s = \varepsilon_0 = 0{,}2$. El ajuste penalizado y las probabilidades 0/1 requieren un intervalo y un tratamiento del logit definidos de antemano; un punto estimado no habilita autonomía. Con pocos datos el resultado es «no habilitada». Se mide la calidad perdida por los vetos. El TOST de la brecha local de la sección 5.7 tiene otro estimando.

4. Calibración, regret e incentivos

La calibración solo cambia decisiones cuando los umbrales salen de costos fijados de antemano; esta sección muestra por qué, define cómo se mide su valor y describe cómo se protege la probabilidad de los incentivos.

4.1 Tres magnitudes

La probabilidad verdadera p es una frecuencia en una población definida, condicional a x, y nunca se observa. La confianza declarada $\tilde{p}$ es una señal que emite el LLM o la persona que decide; no dice nada sobre el acierto mientras no se contraste con resultados, y puede inflarse por incentivos. La estimación calibrada $\hat{p}$ mapea señales a probabilidades y se verifica fuera de

la muestra de ajuste. Toda probabilidad del sistema lleva un estado de validación: señal cruda, heurística, o calibrada y validada en prueba.

4.2 Métricas

El Brier es la medida principal de calidad probabilística, reportado con su descomposición de Murphy (1973) en fiabilidad (REL, calibración), resolución (RES, discriminación) e incertidumbre (UNC, que solo depende de los datos):

$$BS = \frac{1}{N}\sum_i (\hat{p}_i - y_i)^2 = \underbrace{\sum_k \tfrac{n_k}{N}(\hat{p}_k - \bar{o}_k)^2}_{REL} - \underbrace{\sum_k \tfrac{n_k}{N}(\bar{o}_k - \bar{o})^2}_{RES} + \underbrace{\bar{o}(1-\bar{o})}_{UNC}$$

La identidad es exacta cuando las bandas son los valores distintos de $\hat{p}$. La log-loss (con $\hat{p}$ recortada a [0,01; 0,99]) y el AUROC se reportan por separado, para distinguir «calibrado pero inútil» de «discrimina pero mal calibrado».

El Brier skill score $\mathrm{BSS} = 1 - BS/BS_{ref}$ necesita una referencia fijada de antemano. **La referencia es una tasa base histórica de un período previo, fijada antes de la evaluación.** Una tasa base dejando fuera cada caso (LOO) no es intercambiable con la tasa en muestra: con resultados binarios, su Brier es exactamente la incertidumbre en muestra multiplicada por $(n/(n-1))^2$, así que es una referencia más fácil de superar que la tasa en muestra (con $n = 8$, un 31 % más alta). No es un artefacto: es el Brier fuera de muestra de una tasa base estimada con $n - 1$ casos. Se reporta como cifra secundaria, con esta nota.

El error de calibración esperado (ECE) es secundario. Para un predictor perfectamente calibrado ($p \sim \mathrm{Beta}(4, 2)$, bandas de igual masa, 500 réplicas) su valor esperado es 0,077 con $n = 200$ y $M = 10$ bandas, y 0,156 con $n = 50$ (simulado: bandas de igual masa por orden de p, semilla 20261025; un script local reproduce esas cifras al redondeo publicado — ver Disponibilidad). Que sea reproducible hoy no prueba la procedencia histórica del generador. Son resultados de un predictor perfectamente calibrado, no observaciones experimentales ni prueba de calibración del sistema. A esta escala el ECE crudo no sirve como criterio de descarte; se reporta con corrección de sesgo (Kumar, Liang y Ma, 2019; Roelofs et al., 2022). Las curvas de calibración muestran n por banda con intervalo de Wilson (1927) al 95 %; las bandas con $n < 10$ van en gris, y con n chico una curva logística suave (intercepto y pendiente) reemplaza a las bandas sueltas.

Límite [HEUR]. Mejorar el ECE (o ajustar un calibrador isotónico) no implica, por sí solo, mejor discriminación (RES), mejor ejecución ni mayor seguridad. Calibración, discriminación y seguridad se reportan por separado.

4.3 Invariancia con presupuesto igualado

Sea g estrictamente creciente. Con un único score, $\{s > t\} = \{g(s) > g(t)\}$ cuando también se transforma el umbral. A presupuesto ordinal igualado y con la misma resolución de empates, se seleccionan los mismos casos y se obtiene la misma utilidad [DEM]. Eso se refiere a posiciones de orden, no a igualdad numérica de cuantiles interpolados, y no vale si se mantiene el mismo umbral numérico derivado de costos. Platt requiere pendiente positiva; la isotónica solo es no decreciente y puede crear empates, de modo que no garantiza igualdad de acciones, AUROC ni curva riesgo–cobertura. En simulación, con un presupuesto del 25 % de preguntas, la fracción de decisiones distintas entre el score crudo y el recalibrado con Platt es exactamente 0,0. Tampoco se garantiza la invariancia para políticas que combinan varias probabilidades (por ejemplo $p \cdot r$ o $q_2 \alpha W$) o umbrales por caso.

La consecuencia para la evaluación: comparar una política calibrada con una sin calibrar a presupuesto ordinal igualado mide solo discriminación. En esa comparación de un score, la calibración importa cuando el umbral se deriva de costos.

4.4 Regret

Para un score s y un umbral a priori t_a derivado de costos, el regret es la utilidad perdida respecto del mejor umbral para ese mismo score, elegido ex post en la prueba:

$$\mathrm{Reg}(\pi_s) = \max_t \bar{U}(s,t) - \bar{U}(s,t_a)$$

Ilustración sintética ($b = 1$, $c = 3$, $r = 0{,}8$, $k = 0{,}3$, de modo que $p^* = 0{,}906$; $p \sim \mathrm{Beta}(2,1)$; score crudo sobreconfiado $\mathrm{expit}(3\,\mathrm{logit}\,p)$; Platt ajustado en 3.000 casos; prueba con 200.000; semilla 20261025):

Score	Tasa de preguntar	Utilidad media
Crudo (sobreconfiado)	0,463	0,346
Recalibrado (Platt)	0,809	0,466
Probabilidad verdadera	0,821	0,466
Crudo con umbral óptimo ex post	—	0,466

El score crudo discrimina igual que los otros (con su umbral oráculo alcanza la utilidad máxima) y pierde unos 0,12 solo porque el umbral derivado de costos cae en el lugar equivocado de su escala. Ese regret ilustra lo que puede aportar la calibración en el ejemplo.

La ecuación publicada es el regret empírico Reg_n respecto de un oráculo seleccionado en la misma partición de prueba, no el regret poblacional Reg_P. Condicional a modelos ajustados fuera de prueba, $\mathrm{Reg}_P(s) = \sup_t U_P(s,t) - U_P(s,t_a)$ y $\mathrm{Reg}_n(s) = \max_t \bar{U}_n(s,t) - \bar{U}_n(s,t_a)$. Hay que fijar la familia de umbrales $\mathcal{T}$ (con t_a, extremos y desempates). Para candidatos independientes de los resultados y medias insesgadas, $E[\max_t \bar{U}_n(s,t)] \geq \sup_t U_P(s,t)$, de modo que el regret absoluto es optimista y tiende a exceder el poblacional; al inferir, el máximo se recalcula en cada remuestra.

Si $s_c = g(s)$ con g estrictamente creciente y se evalúan las mismas muestras, utilidades, vetos, desempates y familias de políticas en correspondencia, $\mathrm{Reg}_n(s) - \mathrm{Reg}_n(s_c) = \bar{U}_n(s_c,t_a) - \bar{U}_n(s,t_a)$: el oráculo se cancela en la diferencia de DG-H1b. Eso vale, por ejemplo, con Platt estrictamente creciente del mismo N2, el mismo N de prueba y las mismas políticas, utilidades y casos. No se impone aquí que N2c se construya sobre N2 ni se afirma un sesgo automático. Con isotónica y empates nuevos, N2c sobre N1, Platt no creciente o grillas no correspondientes, no se presume esa cancelación.

4.5 Curva de decisión para actuar frente a preguntar

El beneficio neto estándar de Vickers y Elkin (2006) compara actuar con «no tratar a nadie». Aquí la referencia pertinente es «preguntar siempre». Actuar en un caso con $Y_1 = 1$ ahorra k; actuar en uno con $Y_1 = 0$ pierde en esperanza $r(b+c) - k$. En unidades de k [DEM]:

$$NB_{\mathrm{act}|\mathrm{preg}}(t) = \frac{VP}{n} - \frac{FP}{n} \cdot \frac{t}{1-t}, \qquad \frac{t}{1-t} = \frac{r(b+c)-k}{k}$$

Si $0 < k < r(b+c)$ y $t = p^*$, los dos lados de la segunda identidad coinciden. Al variar t, el último peso representa la razón de costos correspondiente a ese t; no es una identidad para cualquier

t manteniendo costos fijos. Vale con r constante; si r o los costos varían por caso, la curva se calcula como utilidad media realizada. Los casos $k = 0$ o $t = 1$ se comparan directamente en utilidad, sin división singular. La curva estándar se reporta como secundaria.

4.6 Incentivos y separación de roles

Lovén et al. (2026) estudian un agente que reporta una confianza antes de actuar, una compuerta que aprueba o rechaza, y un pago que combina una regla de puntuación propia (peso w_C) con un premio por ser aprobado (peso w_A). Aquí se usan tres resultados. Con una compuerta escalón en un umbral, el agente infla su reporte hasta el umbral siempre que el premio a la autonomía supere la pérdida de puntuación de hacerlo, y detectar una inflación interior Δ requiere del orden de $1/\Delta^2$ observaciones. En el régimen no saturado, un escalón ubicado en el umbral más $\sqrt{w_A R^*/w_C}$, donde R^* es la recompensa de la tarea por la acción aprobada, aprueba exactamente los tipos por encima del umbral buscado, con los reportes acumulados en ese punto. Y un crítico informado con $w_A = 0$ que produce la entrada de la compuerta elimina el incentivo a inflar el reporte (a costa de otras propiedades del trilema).

La amenaza para esta propuesta es directa. La relajación lagrangiana de un presupuesto de interrupciones maximiza $E[S(a)] - \lambda_I E[N_{int}(a)] - \lambda_T E[T(a)]$. El término $\lambda_I \cdot$interrupciones premia no preguntar, es decir, actuar, y por lo tanto cumple el papel de w_A. Si el mismo componente que emite p se entrena o se ajusta con ese objetivo, se predicen inflación y acumulación justo arriba de p^*. El mecanismo opera por entrenamiento o ajuste conjunto; un LLM con prompt fijo no lo activa directamente, salvo que ya haya aprendido a inflar (por ejemplo, por sicofancia; Sharma et al., 2024). Un Brier global o un ECE no revelan la acumulación.

Separación de roles [HEUR]. La probabilidad que entra a los umbrales la produce un calibrador g ajustado sobre el registro de decisiones con resultados observados, cuyo único objetivo es una regla de puntuación propia. Ningún componente que optimice interrupciones, tokens o latencia puede modificar g ni sus entradas sin auditoría. La $\tilde{p}$ declarada es una entrada de g; el número que decide es $\hat{p} = g(\tilde{p}, x)$. Si g o sus entradas se ajustan con una recompensa que favorece actuar, vuelve la presión hacia la inflación.

Umbral corregido (secundario). Si un componente con incentivo de autonomía tiene que emitir p y no puede separarse, el umbral puede correrse a $p^* + \sqrt{\lambda_I R^*/w_C}$, bajo supuestos fuertes: compuerta escalón, regla de Brier, R^* homogéneo y conocido, régimen no saturado y $\lambda_I R^*/w_C$ conocido. El número reportado deja entonces de estar calibrado, lo que inutiliza el registro para auditar. La separación de roles no necesita ninguno de esos supuestos.

Elicitación humana. Cuando una persona declara $\tilde{p}$, la IA no propone una probabilidad antes. Se registran la creencia cruda (antes de ver historial o sugerencias) y la ajustada (después), y se puntúan por separado.

5. Experimento 1: diseño

El Experimento 1 del **diseño general de este paper (DG-E1)** es offline, usa casos etiquetados, corre todas las políticas sobre cada caso y tiene una única hipótesis primaria (DG-H1b); todo lo demás es secundario con corrección de Holm (Holm, 1979). Los valores marcados «provisional» son valores por defecto a confirmar en un preregistro. La parametrización de este diseño (grilla de costos, particiones 650–700, niveles N0–N2k) **no es** la de PO430 (sección 5.11): son objetos relacionados y trazables, no el mismo estudio.

5.1 Regímenes de evidencia

Régimen	Qué permite concluir	Qué no permite concluir
Offline con casos etiquetados	Calidad de predicción, calibración, discriminación y utilidad de la política con etiqueta conocida; contrafactuales, porque todos los brazos corren sobre el mismo caso	Atención, preferencias o comportamiento de personas
Simulación con usuarios artificiales	Robustez y sensibilidad; depuración	Nada sobre comportamiento humano
Registro observacional de un sistema personal de agentes	Ilustrar el método; detectar problemas de registro; órdenes de magnitud	Calibración del sistema (n chico, dependencia, autoevaluación, retroalimentación tipo bandit)
Usuarios reales (etapa 2)	Costo de atención, aceptación, overrides, preferencias	Generalización más allá de los usuarios y tareas observados

5.2 Resultado y eventos

El resultado primario es $Y = 1$ si el entregable final cumple el criterio de éxito preregistrado del caso, observable para cada política en cada caso. Y_1 (interpretación correcta en atributos críticos definidos de antemano), Y_2 (el recurso resuelve o abrevia materialmente la petición con modificación acotada) e Y_r (tras una pregunta, la interpretación coincide con la intención) son predictores intermedios, no el resultado. Así el supuesto «aclarar implica ejecutar bien» queda fuera del resultado por construcción. Un criterio operativo que juzgue solo la interpretación (etiqueta «entendió») mide algo cercano a Y_1, no a Y; no deben usarse con el mismo nombre sin declarar cuál.

Offline, r queda sesgada hacia 1 si la respuesta a la pregunta la da quien escribió la intención. Por eso la responde otra persona, o se simula con ruido.

5.3 Hipótesis

- **DG-H1b (primaria, calibración).** Con umbrales derivados de costos sobre una grilla preregistrada de (b, c, k), la política basada en el modelo recalibrado N2c tiene menor regret que N2 sin calibrar: $\mathrm{Reg}(N2c) < \mathrm{Reg}(N2) - \delta_{reg}$, con el regret en unidades de b y $\delta_{reg} = 0{,}05$ (provisional).
- **DG-H1a (discriminación).** A presupuesto de interrupciones B_I fijo, la política basada en N2 alcanza una tasa de éxito S sobre Y mayor que la heurística N1, con efecto mínimo $\Delta_{min} = 0{,}10$ en tasa de éxito. Como N1 produce scores discretos con muchos empates, el presupuesto se cumple exactamente aleatorizando entre los casos empatados en el corte.
- **DG-H2 (calidad probabilística).** La recalibración mejora el Brier, REL y la log-loss sin empeorar RES. El ECE sigue siendo secundario en este marco (sección 4.2); usarlo como criterio de «se sostiene» en un protocolo derivado introduce una tensión con esa cautela y debe declararse (sección 5.11).
- **DG-H3 (recordar).** Decidir recordar con la regla conjunta de la sección 3.5 mejora la utilidad frente a «recordar siempre» y «nunca» en el subconjunto de recordar (sección 5.6).
- **DG-H4 (inflación).** Cuando al componente que decide se le dice que las interrupciones cuentan en su contra, su $\tilde{p}$ declarada se desplaza hacia arriba y se acumula justo arriba del umbral, y la tasa de éxito justo arriba del umbral queda por debajo de la media declarada (sección 5.7).

[CONJ] La evidencia sobre la calibración de la confianza de los LLM es mixta: la confianza

verbalizada tiende a la sobreconfianza (Xiong et al., 2024), aunque en modelos ajustados con RLHF puede estar mejor calibrada que sus probabilidades condicionales (Tian et al., 2023), y la autoevaluación de modelos preentrenados aparece mayormente calibrada (Kadavath et al., 2022). Si discrimina pero calibra mal, DG-H1a puede dar negativo y DG-H1b positivo. Las dos lecturas están previstas.

5.4 Modelos y baselines

Cada nivel se conserva solo si supera al anterior.

Nivel	Modelo	Rol
N0	Tasa base constante	Referencia de utilidad
N1	Umbrales heurísticos sobre señales observables (atributos sin especificar, similitud de recuperación, categoría de tarea)	Baseline a superar
N2	Logística regularizada con las señales de N1, historial de sesión y $\tilde{p}$ como covariable; ablación	Interpretable y estable con pocos datos
N2c	Recalibración de Platt de N1 o N2 en un conjunto de calibración separado (a fijar en el preregistro de DG-E1); isotónica solo con al menos 200 casos de calibración, umbral heurístico (en PO430 el ajuste no irreducible queda al límite; sección 5.11)	Contrasta DG-H1b y DG-H2
N2k	Conjunto conformal sobre interpretaciones candidatas; pregunta si no es unitario (Ren et al., 2023)	Secundario; solo en el plano de la decisión, barriendo α
C1	Comparador publicado (Dong et al., 2026)	Secundario, si se reproduce en tiempo acotado

Controles de fuga: particiones estrictas que agrupan repeticiones y peticiones derivadas de una misma tarea; variables calculadas solo con lo conocido al decidir; selección de modelos nunca sobre la prueba; evaluación en tareas no vistas; documentar si los casos pudieron estar en el entrenamiento del LLM. El número de repeticiones del LLM y la temperatura se preregistran; la $\tilde{p}$ media por caso es la covariable y su desvío una covariable secundaria.

5.5 Comparaciones y tamaño de muestra

La unidad de análisis es el caso; las repeticiones se anidan en él. La superioridad se evalúa contra el margen preespecificado con bootstrap por conglomerados (remuestreando casos) o un GLMM con efecto aleatorio de caso (McNemar solo después de agregar a un único binario por caso y política). La no inferioridad de N1 frente a N2 se retiene si el límite inferior del intervalo al 90 % de $S(N1) - S(N2)$ supera $-\delta$, con $\delta = 0{,}05$.

Para DG-H1a, la aproximación de McNemar ($\alpha = 0{,}05$ bilateral, potencia 0,8; Connor, 1987) da 155 casos para $(\Delta, \psi) = (0{,}10;\ 0{,}20)$, donde ψ es la tasa de discordancia, y 312 para $(0{,}05;\ 0{,}10)$. Esas cifras dimensionan un contraste de igualdad frente a un nulo 0; no demuestran potencia 0,8 para una superioridad sobre un margen de 0,10 cuando el efecto verdadero también es 0,10, ni incorporan Holm ni la dependencia por familia. Los efectos menores a 0,10 quedan fuera de ese alcance, y «no detectado» no significa «no existe». La potencia de DG-H1b para el margen 0,05, y la agregación de la grilla de costos, permanecen pendientes.

Las particiones suman:

Partición	Casos	Propósito
Entrenamiento	150–200	Ajustar N2
Calibración	200	Ajustar Platt; habilita la isotónica
Prueba	200	DG-H1a, DG-H1b, DG-H2
Subconjunto de recordar	100	DG-H3 (cerca de la mitad donde el usuario posee el artefacto, la mitad señuelos)
Total	**650–700**	Unas 75–80 horas con dos anotadores a 3,5 minutos por caso cada uno

El brazo de H4 reutiliza los casos de prueba y solo agrega corridas del LLM, no anotación.

5.6 Subconjunto de recordar

Recordar es el elemento menos estudiado de la propuesta, así que tiene sus propios datos. Los casos se construyen a partir de una biblioteca personal real de skills: peticiones donde una skill o artefacto existente resuelve o abrevia materialmente la tarea, mezcladas con señuelos donde el recurso más cercano no es relevante. Y_2 se etiqueta con independencia del score de recuperación. La adopción α no se observa offline y se barre sobre un rango preregistrado; la conclusión de H3 se expresa en función de α.

5.7 Brazo de incentivo (H4)

El mismo modelo y los mismos casos corren bajo dos condiciones de prompt: neutral, y una que indica que cada interrupción cuenta en contra de la evaluación del agente. Esto contrasta si un incentivo declarado, por sí solo, desplaza los reportes; no reproduce la inflación inducida por entrenamiento, que queda fuera de alcance.

Se mide, por clase de riesgo y umbral t: el desplazamiento pareado de la $\tilde{p}$ media por caso entre condiciones; la acumulación arriba de t; y la tasa de éxito en $[t, t + \varepsilon_u]$ frente a la media declarada, con TOST y $\varepsilon_u = \delta_u = 0{,}10$. El TOST es un criterio para habilitar autonomía, no un detector de inflación: con $n = 160$ declara equivalencia en el 36–43 % de las réplicas, haya o no inflación (simulado). La lectura de inflación es el contraste unilateral $\bar{Y} < \overline{\tilde{p}}$ en ese tramo. Con $\tilde{p}$ declarada en una grilla de 0,05 el test de densidad continuo de McCrary (2008) no aplica, así que la acumulación se contrasta con un test exacto de Fisher unilateral sobre la tabla 2×2 (punto de grilla inmediatamente arriba frente a inmediatamente abajo de t, por brazo), que usa el brazo neutral como control de la forma de la distribución de $\tilde{p}$. Como los dos brazos corren sobre los mismos casos, el Fisher **no ajusta el pareo**. En los escenarios simulados concretos mostró un tamaño de aproximadamente 2,7–3,0 % al 5 % nominal; eso no es un teorema general. El Mantel–Haenszel de PO430 tampoco ajusta el pareo (sección 5.11). En la simulación de diseño (los mismos casos en los dos brazos) la potencia del Fisher es 0,70 con $n = 160$ e inflación $\pi_{inf} = 0{,}4$ (simulado). El test binomial sobre los dos puntos adyacentes, que supone una densidad localmente plana, se reporta solo como descriptivo. Detectar un desvío de calibración de 0,05 requiere varios cientos de decisiones por clase, así que los resultados por clase son descriptivos a esta escala; el desplazamiento pareado de $\tilde{p}$ es la magnitud con más potencia.

Complementarios propuestos, no preregistrados (exploratorios; no sustituyen la primaria). Pendientes de decisión explícita antes de una corrida completa, definidos sobre el conjunto completo de casos y no sobre quienes cayeron en la franja tras ver $\tilde{p}$: (i) McNemar por caso sobre un binario fijado de antemano (p. ej. «cayó en el punto de grilla inmediatamente arriba»); (ii) permutación de la etiqueta de brazo dentro del caso o dentro de la familia de plantilla; (iii) test condicional a los pares discordantes. Ninguno se eleva a primaria en este manuscrito.

5.8 Reglas del registro

El registro debe permitir reconstruir y puntuar después cada decisión.

1. **Bloqueo al cargar.** Predicción, probabilidad y criterio de éxito se fijan con sello de tiempo verificable. Cualquier cambio crea un registro nuevo fechado; el anterior se conserva.
2. **La probabilidad inicial es la principal.** Las actualizaciones se puntúan aparte, cada una con su horizonte, porque una actualización tardía tiene más información.
3. **El proceso es covariable.** El proceso ex ante se registra como covariable y nunca se usa para declarar buena una decisión con independencia de su resultado.
4. **Política de registro fija.** Se registran todas las decisiones R2 y R3; las R0 y R1, todas o una muestra aleatoria preespecificada. Registrar solo los casos memorables sesga la calibración.
5. **Primero la persona.** La IA nunca propone una probabilidad antes que la persona.
6. **Gráficos honestos.** n por banda, intervalo de Wilson, bandas en gris con $n < 10$.

Las etiquetas no deben derivarse de las propias entradas del modelo. Si un LLM actúa como juez, se valida contra anotación humana (kappa de Cohen, 1960, o alfa de Krippendorff, 2018) y usa un modelo o prompt distinto del que genera las señales.

5.9 Auditoría de calibración por clase

Para detectar un desvío $\Delta = |p_1 - p_0|$ con un test binomial unilateral, la aproximación normal da:

$$n \approx \frac{\left(z_{1-\alpha}\sqrt{p_0(1-p_0)} + z_{1-\beta}\sqrt{p_1(1-p_1)}\right)^2}{\Delta^2}$$

Con $p_0 = 0{,}8$, $\Delta = 0{,}05$, $\alpha = 0{,}05$ y potencia 0,8 son 368–419 decisiones por clase. Mientras una clase no llegue a ese tamaño, su tasa de éxito se estima con agrupamiento parcial entre clases:

$$x_j \mid \theta_j \sim \mathrm{Bin}(n_j, \theta_j), \quad \theta_j \sim \mathrm{Beta}(\mu\kappa, (1-\mu)\kappa), \quad \mu \sim U(0,1), \quad \log\kappa \sim U(0, \log 100)$$

La brecha de calibración de la clase j es θ_j menos su probabilidad declarada media, reportada con su intervalo creíble al 90 %. Los umbrales se ajustan solo si la probabilidad posterior de una brecha supera 0,9 en una revisión periódica fija, nunca con pasos ad hoc de $\pm 0{,}05$; cuando el flujo sea estable se usa un test secuencial (SPRT o e-valores). Las clases están ordenadas por riesgo, así que la intercambiabilidad es un supuesto; una logística con efecto aleatorio de clase sobre $\mathrm{logit}\,\tilde{p}$ es el análisis principal cuando $n \geq 30$.

5.10 Preregistro

Antes de abrir la partición de prueba de DG-E1 se fija un documento fechado con la métrica primaria, los márgenes, la grilla de costos, los tamaños de muestra, los hiperpriors, la política de registro y el código de análisis corrido sobre datos sintéticos de la misma estructura. Un registro público (p. ej. OSF Registries) es deseable; **este manuscrito no afirma que ese registro ya exista para el diseño general**. PO430, firmado localmente el 01/11/2026, es un archivo local; no se afirma un registro público verificable de esa fecha. Su depósito, si se hiciera, sería distinto del de este manuscrito.

5.11 Relación con la implementación preregistrada (PO430)

El 01/11/2026 se congeló un protocolo operativo derivado de esta propuesta (PO430; «Experimento 1, implementación preregistrada»), con banco de 430 pedidos etiquetados, un modelo fijo, dos brazos pareados (control e incentivo), calibrador isotónico y partición 215/215. **PO430 no es una corrida del diseño DG-E1 de las secciones 5.3–5.5** y **no contrasta la hipótesis primaria DG-H1b**. Presentarlo como prueba de DG-H1b sería un cambio de sustancia, no una aclaración.

Objeto	DG-E1 (diseño general, §§5.3–5.5)	PO430 (protocolo operativo, 01/11/2026)
Alcance	Offline; niveles N0–N2k; ~650–700 casos	Un modelo; 430 pedidos; sin niveles N1/N2/N2c; calibrador isotónico
Hipótesis primaria	**DG-H1b**: $\mathrm{Reg}(N2c) < \mathrm{Reg}(N2) - \delta_{reg}$	**PO430-H1**: Mantel–Haenszel unilateral de inflación (3 clases); se sostiene si $p < 0{,}05$ y OR común > 1
Inflación	**DG-H4** (secundaria; §5.7)	PO430-H1 ($\approx$ DG-H4)
Calidad probabilística	**DG-H2** (Brier/REL/log-loss; ECE secundario)	PO430-H2: el criterio de «se sostiene» es el IC de la diferencia de ECE (10 bins); el Brier se reporta como descriptivo; calibrador vs $\tilde{p}$, en prueba
Utilidad / regret	DG-H1b mide regret frente al umbral óptimo *ex post* del mismo score (§4.4)	PO430-H3: pérdida de utilidad vs «actuar si $p > 0{,}5$; si no, preguntar» (**no es DG-H1b**)
Discriminación a presupuesto fijo	DG-H1a	Sin contraparte confirmatoria
Recordar	DG-H3	Fuera del alcance de esa implementación
Parámetros	Grilla preregistrada de (b, c, k); r según diseño	Congelados: $b = 1$; $c = 1/2/4$; $k = 0{,}2$; $r = 0{,}925/0{,}896/0{,}646$ por clase (parámetros de diseño, no una estimación validada de r_0)
Partición calibrador	Entrenamiento / calibración / prueba (§5.5)	215 ajuste / 215 prueba; PO430-H2 principal en 200 no irreducibles de prueba

Tensiones y pendientes declaradas (no son enmiendas aplicadas). Ninguna altera en silencio una primaria, una semilla, un banco ni un éxito definido:

1. **Bins del ECE.** El paper habla de bandas de igual masa en la simulación nula; el preregistro dice «10 bins iguales»; el plan de análisis dice «igual frecuencia». No son lo mismo. Pendiente antes de la corrida confirmatoria de PO430-H2 (bordes y empates incluidos).
2. **N dentro de la franja.** El cálculo orientativo de ~131 casos *por brazo dentro de* $\{g^-, g^+\}$ no es un N global ni 131 de los 430. Sin distribución documentada de $\tilde{p}$ en el banco, la po-

tencia del Mantel–Haenszel **no está confirmada**. La enmienda 1 del protocolo exige fijar N tras el piloto; esa fijación **aún no existe**. La potencia de DG-H1b también permanece pendiente.

3. **Familias / conglomerados.** El banco completo tiene 24 familias. La hipótesis PO430-H2 principal excluye las seis familias de irreducibles y conserva 18; H3 con el banco completo requiere considerar las 24 en la sensibilidad pertinente. No se pasa todo a 24. La partición por pedido evalúa pedidos nuevos dentro de plantillas compartidas entre ajuste y prueba, no familias inéditas.
4. **Pareo.** El Mantel–Haenszel estratifica por riesgo y no ajusta el pareo por pedido ni la dependencia por familia; su validez nominal y su potencia no están verificadas (ya notado en §5.7). Los complementarios **propuestos, no preregistrados**, de esa sección siguen exploratorios y no se elevan a primaria.
5. **ECE como criterio de PO430-H2.** Choca con la cautela de §4.2 («el ECE crudo no sirve como criterio de descarte»). La diferencia pareada atenúa el sesgo común pero no elimina necesariamente el sesgo de estimación de cada método ni artefactos por empates o isotónica. Declarado aquí; corregir solo por enmienda.
6. **Isotónica al límite.** El umbral de diseño «$\geq$ 200 casos de calibración» es heurístico, no una validación de calibración. Se cumple al límite en el ajuste no irreducible del banco de 430 si el calibrador se ajusta solo en control; no se eleva el plan por encima del preregistro en este manuscrito.
7. **Etiqueta o horizonte de H2.** No está cerrado si la probabilidad inicial se puntúa contra la interpretación inicial o contra la interpretación posterior cuando se pregunta. Pendiente; no se adjudica aquí.
8. **Calibrador de DG-E1 (N1 o N2) y agregación de costos.** Permanecen abiertos, igual que los métodos confirmatorios complementarios y la familia exacta de secundarios bajo Holm.

Si se quisiera que PO430 contraste DG-H1b, hace falta una enmienda prospectiva **antes** de la corrida completa. Este manuscrito no la redacta ni altera primarias, semillas, umbrales o datos congelados.

6. Piloto ilustrativo

El método se puede ejecutar de punta a punta sobre un registro real de decisiones, y el ejercicio sobre todo muestra sus límites: 8 de 25 decisiones registradas son evaluables, y nada de lo que sigue dice si el sistema está calibrado. El piloto ilustra; no valida.

Fuente. El registro de decisiones (25 filas) de un sistema personal multiagente operado por el autor. Limitaciones: n chico; decisiones de un mismo proyecto, no independientes; mezcla de decisiones del sistema y del propietario; probabilidades subjetivas declaradas por el propio sistema, que además definió y juzgó varios criterios de éxito (autoevaluación); retroalimentación tipo bandit. No se imputó ningún valor.

Inclusión. Se incluyeron solo filas con $\tilde{p}$ declarada, clase de riesgo, umbral, criterio registrado y resultado binario observado, y donde decidió el sistema. Ocho filas cumplen (R0: 7, R1: 1; un fracaso). Una decisión del propietario, cuyo criterio mide si hubo decisión y no si la recomendación fue acertada, entra solo como sensibilidad. Las otras 16 se excluyeron por motivos documentados: no ejecutadas, sin $\tilde{p}$, sin criterio, criterio que nunca se activó o resultados mixtos no binarios.

Resultados ($n = 8$, 7 éxitos, $\tilde{p}$ media $= 0{,}750$).

Medida	Valor
Brier (intervalo bootstrap 95 %, 10.000 remuestras)	0,1325 [0,043; 0,248]
Descomposición de Murphy	REL 0,070 · RES 0,047 · UNC 0,109
Log-loss	0,412
AUROC	0,64 (un solo fracaso: no informativo)
BSS frente a la tasa base en muestra	−0,21
BSS frente a la tasa base LOO (secundario)	+0,07; la diferencia con la cifra en muestra se debe por completo al factor $(8/7)^2$ de la referencia LOO
Posterior jerárquica, R0 (6/7, declarada 0,743)	mediana 0,83, intervalo 90 % [0,57; 0,97], $P(\theta <$ declarada$) = 0{,}28$
Posterior jerárquica, R1 (1/1, declarada 0,80)	mediana 0,83, [0,45; 1,00]; casi todo agrupamiento
Pendiente de calibración penalizada	0,27 (logística ridge, $C = 1$); muy imprecisa y sensible a la penalización; no permite validar calibración. El veto de validación deja todas las clases no habilitadas

Todavía no existe un período histórico de referencia, así que no se reporta el BSS principal. Las tres bandas de calibración tienen $n < 10$ y van en gris; cada intervalo de Wilson contiene las probabilidades declaradas de su banda. La lectura descriptiva es subconfianza (7 éxitos de 8 con una media declarada de 0,75), pero con ocho casos el término de fiabilidad está dominado por ruido. En estos ocho casos la MLE logística sin penalizar es finita (pendiente aproximada 0,718); ese chequeo no sustituye el resultado penalizado ni habilita inferencia confirmatoria. El intervalo bootstrap es descriptivo bajo remuestreo iid.

Lo que el piloto sí justifica son las reglas de registro de la sección 5.8: predicciones bloqueadas, criterios registrados para cada decisión, incluidas las del propietario, y una política de registro fija.

7. Limitaciones

1. **Sin validación experimental de DG-E1 ni de PO430.** Ninguno se ejecutó. Hay derivaciones, simulaciones ilustrativas (secciones 4.2, 4.4 y 5.7; scripts locales con semilla 20261025 que hoy reproducen esas cifras, sin prueba de procedencia histórica) y un piloto ilustrativo de ocho decisiones.
2. **Escala.** El diseño detecta efectos de alrededor de 0,10 en tasa de éxito frente a un nulo 0, con las salvedades de la sección 5.5. Auditar la calibración por clase con $\Delta = 0{,}05$ requiere unas 370–420 decisiones por clase, inalcanzable a corto plazo con un solo usuario; mientras tanto la evidencia por clase es jerárquica y descriptiva.
3. **Costos desconocidos.** b, c, k, k_E y W no se miden directamente; las conclusiones valen dentro de la grilla preregistrada.
4. **Supuestos de la regla de decisión.** El marco es de un paso. Las derivaciones identifican $Y^{\text{act}} = Y_1$ ($e_1 = 1$, $e_0 = 0$) y suponen independencia de r respecto del acierto inicial dado x; r es constante; alcanza con una pregunta; recordar es aditivo en el caso base. Cada uno se examina con sensibilidad, no con una prueba completa. Fuera de la idealización no se garantiza optimalidad ni que calibrar p calibre el éxito final.
5. **La r offline es optimista** si quien responde conoce la intención. Las r congeladas de PO430 son parámetros de diseño, no una estimación validada de r_0.

6. **No estacionariedad.** La calibración y las garantías conformales no se transfieren cuando cambian el modelo base, los prompts o la biblioteca de skills.
7. **Retroalimentación tipo bandit** en uso real: solo se observa la salida elegida; la evaluación off-policy se difiere.
8. **Separación de roles imperfecta.** El calibrador protege el número que decide, no la señal de entrada. Actuar según $\hat{p}$ cambia qué casos se observan (predicción performativa; Perdomo et al., 2020).
9. **El brazo de incentivo** contrasta un incentivo declarado, no la inflación inducida por entrenamiento.
10. **El piloto** tiene $n = 8$, está autoevaluado, no es independiente y no es generalizable; no es un experimento de política.
11. **La búsqueda bibliográfica** no fue sistemática.
12. **Dos protocolos.** DG-E1 y PO430 no son el mismo contraste (sección 5.11); PO430 no contrasta DG-H1b y no se afirma un registro público verificable del 01/11/2026.
13. **Pendientes de una corrida confirmatoria, no de este preprint de diseño:** los de la sección 5.11 (calibrador N1 o N2, agregación de costos, nulos y márgenes, etiqueta de H2, bins, N, pareo y potencia de MH, potencia de DG-H1b, familia de secundarios; 18 familias en la H2 principal no irreducible y 24 en el banco completo y en H3).
14. **DOI y depósito.** El DOI de esta versión consta en su registro de Zenodo, no en este PDF. No se afirma un registro OSF, y el preregistro y el plan de análisis no tienen depósito público. No se promete un repositorio público de los datos del piloto.
15. **Resultados de Lovén et al. (2026)** provienen de un preprint.

8. Conclusión

La elección entre actuar, preguntar, abstenerse y recordar puede evaluarse como un conjunto de decisiones con eventos definidos, baselines simples y criterios de descarte declarados antes de ver resultados. El diseño propuesto separa lo que aporta la discriminación de lo que aporta la calibración, mide esto último como regret bajo umbrales derivados de costos, y protege del incentivo a actuar la probabilidad que entra al umbral. DG-E1 y PO430 no tienen validación experimental: este texto es una propuesta de investigación, no una demostración de efectividad. Un resultado negativo sería útil: una heurística que iguale a la política calibrada dentro del margen preespecificado mostraría que, en las condiciones evaluadas, la complejidad adicional no se justifica.

Declaraciones

Uso de herramientas de IA. El manuscrito se preparó con asistencia de herramientas de IA, bajo la dirección y la revisión del autor: Claude, de Anthropic; ChatGPT, de OpenAI, en la fase de revisión final; y un equipo de agentes de IA en Grok Bot (Turing, Gauss, Grove y Bostock), configurado y dirigido por el autor. Su contribución fue sustancial en la búsqueda bibliográfica, la revisión técnica, el código de simulación y la redacción. Todas las decisiones metodológicas, el texto y cada referencia quedan bajo responsabilidad del autor. Ningún sistema de IA figura como autor.

Disponibilidad de datos y código. El código de las simulaciones de las secciones 4.2, 4.4 y 5.7 existe de forma local, con semilla fija 20261025, y hoy reproduce esas cifras; no forma parte de este depósito ni prueba la procedencia histórica del generador. El sitio complementario y su código están en https://github.com/gustavomora/Calibratedagent. No hay datos experimentales de DG-E1 ni de PO430. El registro del piloto es personal y no se publica con esta versión. No se promete un depósito futuro de código ni de datos. El identificador de esta versión es el DOI que le asigna su registro en Zenodo; este PDF no lo incluye.

Conflicto de intereses. Ninguno. Este trabajo se realizó de forma independiente, en tiempo propio y con recursos personales.

Financiamiento. Ninguno.

Licencia. Este manuscrito se distribuye bajo la licencia Creative Commons Atribución 4.0 Internacional (CC BY 4.0).

Referencias

Los preprints no pasaron revisión por pares.

Cemri, M., Pan, M. Z., Yang, S., et al. (2025). Why do multi-agent LLM systems fail? Preprint, arXiv:2503.13657. https://arxiv.org/abs/2503.13657

Chen, V., Zhu, A., Zhao, S., Mozannar, H., Sontag, D., y Talwalkar, A. (2025). Need help? Designing proactive AI assistants for programming. *Proceedings of CHI '25*. https://doi.org/10.1145/3706598.3714002

Chow, C. K. (1970). On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, 16(1), 41–46. https://doi.org/10.1109/TIT.1970.1054406

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46. https://doi.org/10.1177/001316446002000104

Connor, R. J. (1987). Sample size for testing differences in proportions for the paired-sample design. *Biometrics*, 43(1), 207–211. https://doi.org/10.2307/2531961

Ding, D., Mallick, A., Zhang, S., et al. (2025). BEST-Route: Adaptive LLM routing with test-time optimal compute. *Proceedings of ICML 2025*, PMLR 267, 13870–13884. https://proceedings.mlr.press/v267/ding25d.html

Dong, Y. R., Hu, T., Hui, Z., Zhang, C., Vulić, I., Bobu, A., y Collier, N. (2026). Value of information: A framework for human–agent communication. *Proceedings of ACL 2026 (Long Papers)*, 42879–42896. https://doi.org/10.18653/v1/2026.acl-long.1987

Dwork, C., Kim, M. P., Reingold, O., Rothblum, G. N., y Yona, G. (2021). Outcome indistinguishability. *Proceedings of STOC 2021*, 1095–1108. https://doi.org/10.1145/3406325.3451064

El-Yaniv, R., y Wiener, Y. (2010). On the foundations of noise-free selective classification. *Journal of Machine Learning Research*, 11, 1605–1641. https://jmlr.org/papers/v11/el-yaniv10a.html

Feng, K. J. K., McDonald, D. W., y Zhang, A. X. (2025). Levels of autonomy for AI agents. Preprint, arXiv:2506.12469. https://arxiv.org/abs/2506.12469

Geifman, Y., y El-Yaniv, R. (2017). Selective classification for deep neural networks. *NeurIPS 2017*. arXiv:1705.08500. https://papers.nips.cc/paper/7073-selective-classification-for-deep-neural-networks

Hébert-Johnson, U., Kim, M. P., Reingold, O., y Rothblum, G. N. (2018). Multicalibration: Calibration for the (computationally-identifiable) masses. *Proceedings of ICML 2018*, PMLR 80, 1939–1948. https://proceedings.mlr.press/v80/hebert-johnson18a.html

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70. https://doi.org/10.2307/4615733

Holmström, B. (1984). On the theory of delegation. En M. Boyer y R. Kihlstrom (Eds.), *Bayesian Models in Economic Theory* (pp. 115–141). North-Holland. Versión de trabajo (1980): https://ideas.repec.org/p/nwu/cmsems/438.html

Horvitz, E. (1999). Principles of mixed-initiative user interfaces. *Proceedings of CHI '99*, 159–166. https://doi.org/10.1145/302979.303030

Horvitz, E., y Apacible, J. (2003). Learning and reasoning about interruption. *Proceedings of ICMI 2003*, 20–27. https://doi.org/10.1145/958432.958440

Horvitz, E., Koch, P., y Apacible, J. (2004). BusyBody: Creating and fielding personalized models of the cost of interruption. *Proceedings of CSCW '04*, 507–510. https://doi.org/10.1145/1031607.1031690

Kadavath, S., et al. (2022). Language models (mostly) know what they know. Preprint, arXiv:2207.05221. https://arxiv.org/abs/2207.05221

Kapoor, S., Stroebl, B., Siegel, Z. S., Nadgir, N., y Narayanan, A. (2024). AI agents that matter. Preprint, arXiv:2407.01502. https://arxiv.org/abs/2407.01502

Kobalczyk, K., Astorga, N., Liu, T., y van der Schaar, M. (2025). Active task disambiguation with LLMs. *ICLR 2025*. arXiv:2502.04485. https://openreview.net/forum?id=JAMxRSXLFz

Krippendorff, K. (2018). *Content Analysis: An Introduction to Its Methodology* (4.ª ed.). SAGE. ISBN 978-1-5063-9566-1. https://us2.sagepub.com/en-us/nam/content-analysis/book258450

Kumar, A., Liang, P., y Ma, T. (2019). Verified uncertainty calibration. *NeurIPS 2019*. arXiv:1909.10155. https://arxiv.org/abs/1909.10155

Li, F., Tagkopoulos, P., y Tagkopoulos, I. (2025). SkillFlow: Scalable and efficient agent skill retrieval system. Preprint, arXiv:2504.06188. Aceptado en COLM 2026 (según arXiv). https://arxiv.org/abs/2504.06188

Lovén, L., Do, N., Mehmood, H., Sah, D. K., y Tarkoma, S. (2026). The behavioral credibility trilemma: When calibrated autonomy becomes impossible. Preprint, arXiv:2605.25739v2. https://arxiv.org/abs/2605.25739

Lu, Y., Yang, S., Qian, C., et al. (2024). Proactive agent: Shifting LLM agents from reactive responses to active assistance. Preprint, arXiv:2410.12361. https://arxiv.org/abs/2410.12361

Madras, D., Pitassi, T., y Zemel, R. (2018). Predict responsibly: Improving fairness and accuracy by learning to defer. *NeurIPS 2018*. arXiv:1711.06664. https://arxiv.org/abs/1711.06664

McCrary, J. (2008). Manipulation of the running variable in the regression discontinuity design: A density test. *Journal of Econometrics*, 142(2), 698–714. https://doi.org/10.1016/j.jeconom.2007.05.005

Mozannar, H., y Sontag, D. (2020). Consistent estimators for learning to defer to an expert. *Proceedings of ICML 2020*, PMLR 119, 7076–7087. https://proceedings.mlr.press/v119/mozannar20b.html

Murphy, A. H. (1973). A new vector partition of the probability score. *Journal of Applied Meteorology*, 12(4), 595–600. https://doi.org/10.1175/1520-0450(1973)012%3C0595:ANVPOT%3E2.0.CO;2

Parasuraman, R., Sheridan, T. B., y Wickens, C. D. (2000). A model for types and levels of human interaction with automation. *IEEE Transactions on Systems, Man, and Cybernetics – Part A*, 30(3), 286–297. https://doi.org/10.1109/3468.844354

Pauker, S. G., y Kassirer, J. P. (1980). The threshold approach to clinical decision making. *New England Journal of Medicine*, 302(20), 1109–1117. https://doi.org/10.1056/NEJM198005153022003

Perdomo, J., Zrnic, T., Mendler-Dünner, C., y Hardt, M. (2020). Performative prediction. *Proceedings of ICML 2020*, PMLR 119, 7599–7609. https://proceedings.mlr.press/v119/perdomo20a.html

Pu, K., Lazaro, D., Arawjo, I., Xia, H., Xiao, Z., Grossman, T., y Chen, Y. (2025). Assistance or disruption? Exploring and evaluating the design and trade-offs of proactive AI programming support. *Proceedings of CHI 2025*. https://doi.org/10.1145/3706598.3713357

Raj, R., Kundu, S., Joshi, D., y Krishna, T. (2026). ORACLE: Agentic AI orchestrator routing via adaptive verifier calibration feedback. Preprint, arXiv:2607.22465. https://arxiv.org/abs/2607.22465

Ren, A. Z., Dixit, A., Bodrova, A., et al. (2023). Robots that ask for help: Uncertainty alignment for large language model planners. *CoRL 2023*, PMLR 229. arXiv:2307.01928. https://arxiv.org/abs/2307.01928

Rhodes, B. J., y Maes, P. (2000). Just-in-time information retrieval agents. *IBM Systems Journal*, 39(3–4), 685–704. https://doi.org/10.1147/sj.393.0685

Roelofs, R., Cain, N., Shlens, J., y Mozer, M. C. (2022). Mitigating bias in calibration error estimation. *Proceedings of AISTATS 2022*, PMLR 151. arXiv:2012.08668. https://arxiv.org/abs/2012.08668

Ruan, K., Huang, Z., Zhou, Z., Wei, Q., Lin, J., Wang, X., y Sun, H. (2026). Doomed from the start: Early abort of LLM agent episodes via a recall-controlled probe cascade. Preprint, arXiv:2607.06503. https://arxiv.org/abs/2607.06503

Scerri, P., Pynadath, D. V., y Tambe, M. (2002). Towards adjustable autonomy for the real world. *Journal of Artificial Intelligence Research*, 17, 171–228. https://doi.org/10.1613/jair.1037

Schuirmann, D. J. (1987). A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability. *Journal of Pharmacokinetics and Biopharmaceutics*, 15(6), 657–680. https://doi.org/10.1007/BF01068419

Sharma, M., et al. (2024). Towards understanding sycophancy in language models. *ICLR 2024*. https://openreview.net/forum?id=tvhaxkMKAn

Suri, M., Mathur, P., Lipka, N., Dernoncourt, F., Rossi, R. A., y Manocha, D. (2026). Structured uncertainty guided clarification for LLM agents. *Findings of ACL 2026*, 40811–40838. https://doi.org/10.18653/v1/2026.findings-acl.2028

Tian, K., et al. (2023). Just ask for calibration: Strategies for eliciting calibrated confidence scores from language models fine-tuned with human feedback. *Proceedings of EMNLP 2023*, 5433–5442. https://doi.org/10.18653/v1/2023.emnlp-main.330

Vickers, A. J., y Elkin, E. B. (2006). Decision curve analysis: A novel method for evaluating prediction models. *Medical Decision Making*, 26(6), 565–574. https://doi.org/10.1177/0272989X06295361

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158), 209–212. https://doi.org/10.1080/01621459.1927.10502953

Xiong, M., et al. (2024). Can LLMs express their uncertainty? An empirical evaluation of confidence elicitation in LLMs. *ICLR 2024*. arXiv:2306.13063. https://arxiv.org/abs/2306.13063

Yang, G., Zhang, W., Shi, T., y Wang, P. (2026). SkillSeek: Revisiting agent skill retrieval at marketplace scale. *AACL-IJCNLP 2026*. arXiv:2609.38822. https://arxiv.org/abs/2609.38822

Yao, Y., Wang, S., Chen, X., Zhang, M., He, J., Luo, B., y Gedeon, T. (2026). SkillTrace: Traversing a query-skill graph for composable LLM agents. Preprint, arXiv:2608.02356. https://arxiv.org/abs/2608.02356

Ye, Y., y Fischer, G. (2002). Supporting reuse by delivering task-relevant and personalized information. *Proceedings of ICSE '02*, 513–523. https://doi.org/10.1145/581339.581402

Yuan, F., Gao, X., y Lindqvist, J. (2017). How busy are you? Predicting the interruptibility intensity of mobile users. *Proceedings of CHI 2017*, 5346–5360. https://doi.org/10.1145/3025453.3025946

Yue, Y., Zhang, G., Liu, B., Wan, G., Wang, K., Cheng, D., y Qi, Y. (2025). MasRouter: Learning to route LLMs for multi-agent systems. *Proceedings of ACL 2025 (Long Papers)*, 15549–15572. https://doi.org/10.18653/v1/2025.acl-long.757

Zheng, Y., Zhang, Z., Ma, C., et al. (2026). SkillRouter: Skill routing for LLM agents at scale. Preprint, arXiv:2603.22455. https://arxiv.org/abs/2603.22455